

# Agente Inteligente Aspirador de Pó: Uma Abordagem Baseada em Movimentos Pseudo-Aleatórios

1<sup>st</sup> Bárbara Braga Gualberto Correa  
Centro Federal de Educação Tecnológica  
(CEFET/MG)

Divinópolis, Brasil  
barbarabgual@gmail.com

2<sup>nd</sup> Julia Mello Lopes Gonçalves  
Centro Federal de Educação Tecnológica  
(CEFET/MG)

Divinópolis, Brasil  
juliamellolopesgoncalves@gmail.com

**Resumo**—Este artigo apresenta a implementação de um agente inteligente para limpeza automatizada de ambientes utilizando uma abordagem baseada em movimentos pseudo-aleatórios. O agente foi desenvolvido em Python e submetido a simulações para avaliar sua eficácia em ambientes de diferentes configurações de sujeira. Os resultados mostraram que o desempenho do agente varia de acordo com o número de células sujas no ambiente, sendo mais desafiador em ambientes com menos sujeira.

**Index Terms**—Agente Inteligente, Limpeza Automatizada, Movimentos Aleatórios, Inteligência Artificial

## I. INTRODUÇÃO

No âmbito da inteligência artificial, um agente é definido como qualquer entidade capaz de perceber seu ambiente por meio de sensores e tomar decisões ou agir sobre esse ambiente por meio de atuadores ou reagentes [1]. Um agente inteligente, por sua vez, refere-se a uma entidade autônoma e dotada de inteligência, capaz de tomar decisões de forma independente em busca de objetivos específicos.

Neste trabalho, exploramos a implementação e avaliação de um agente inteligente no contexto da limpeza automatizada, especificamente no domínio do aspirador de pó. O objetivo primordial foi realizar uma avaliação inicial do desempenho do agente, sem pressupor a eficácia absoluta de sua estratégia de movimentação.

A abordagem experimental adotada neste estudo permitiu não apenas uma análise detalhada do desempenho do agente em ambientes com diferentes níveis de sujeira, mas também destacou a necessidade de investigações adicionais sobre estratégias mais eficientes para a limpeza automatizada de ambientes. Durante o processo de limpeza, o agente acumula ou perde pontos, proporcionando uma métrica objetiva para avaliar sua eficácia na realização da tarefa proposta.

## II. METODOLOGIA

Nossa abordagem para investigar o comportamento do agente baseou-se em permitir que ele tomasse decisões de

movimento de forma pseudo-aleatória pelo ambiente, sempre levando em consideração os três últimos movimentos que ele realizou. O agente foi implementado em Python e submetido a simulações para avaliar como ele se comporta ao limpar ambientes com diferentes configurações de sujeira, sem seguir uma estratégia específica de movimentação.

### A. Geração Aleatória do Ambiente

Para simular uma variedade de cenários de sujeira, empregamos uma função específica, projetada para preencher uma matriz de dimensões  $m \times n$  com uma quantidade predefinida de células sujas. Nossos experimentos foram conduzidos considerando  $m$  e  $n$  como o valor 4, proporcionando uma base estável para comparação entre os diferentes cenários.

Os experimentos abrangeram cenários com 4, 8, 12 e 16 células sujas, oferecendo uma ampla gama de configurações de sujeira para a avaliação do desempenho do agente. Cada configuração foi submetida a 10 iterações individuais, garantindo resultados consistentes e estatisticamente significativos para análise posterior.

### B. Inicialização do Agente

Em cada experimento, o agente é inicializado em uma posição aleatória dentro da matriz. Sua posição inicial é determinada de forma aleatória, sem qualquer conhecimento prévio sobre sua localização ou a distribuição da sujeira no ambiente. Esta abordagem de inicialização permite uma exploração mais abrangente do espaço de busca e garante uma avaliação imparcial do desempenho do agente em diferentes contextos de limpeza automatizada.

### C. Movimento do Agente

O agente é capaz de se deslocar nas quatro direções possíveis: para cima, para baixo, para a esquerda e para a direita. No entanto, sua estratégia de movimentação não é completamente aleatória; em vez disso, é pseudo-aleatória e baseada nos três últimos movimentos realizados.

Tanto em situações de movimentos válidos quanto de colisões, o agente emprega a mesma abordagem de movimentação pseudo-aleatória. Após cada movimento, o agente verifica se a ação é válida ou inválida, ou seja, resultou em uma colisão. Se for um movimento válido, o agente armazena o movimento inverso realizado, evitando retornar à posição anterior. Por exemplo, se o agente se move para a direita, ele armazena o movimento para a esquerda. Em caso de colisão, como bater em uma parede, o agente ainda armazena o movimento tentado. Isso garante que o agente não repita movimentos que resultaram em colisões anteriores, permitindo uma exploração mais eficiente do ambiente e uma melhor capacidade de limpeza automatizada.

#### D. Limpeza Automatizada

O agente percorre o ambiente, limpando as células sujas encontradas. Caso encontre uma célula suja, ele a limpa e ganha 3 pontos. Por outro lado, a cada movimento realizado, o agente perde 1 ponto.

#### E. Critério de Parada

Para determinar o momento de encerramento de cada experimento, foi adotado um critério baseado na contagem de movimentos do agente. O critério de parada é definido quando a contagem de movimentos do agente atinge a metade do número total de células no ambiente ao quadrado. Considerando uma matriz de dimensões  $m \times n$ , onde  $m$  representa o número de colunas e  $n$  o número de linhas, calculou-se o total de células no ambiente como  $m \times n$ . Em termos matemáticos, o critério de parada pode ser expresso como:

$$\text{Critério de Parada} = \frac{(m \times n)^2}{2}$$

Essa abordagem foi escolhida de forma arbitrária para garantir que os experimentos tenham uma duração finita e controlada, enquanto ainda oferecem tempo suficiente para que o agente explore o ambiente e execute suas ações.

#### F. Avaliação dos Resultados

Para cada configuração de sujeira, realizamos 10 repetições do experimento para garantir valores consistentes e representativos. Os resultados foram analisados, incluindo o melhor resultado, o pior resultado, a média e o desvio padrão das pontuações em cada configuração de sujeira. Durante cada repetição, registramos a pontuação do agente, considerando diversos fatores, como a eficácia da limpeza realizada, o número de movimentos executados e a quantidade de quadrados sujos remanescentes após a conclusão da limpeza. Após a parada do agente, cada quadrado sujo que restou resultou em uma penalização de -20 pontos na pontuação final.

### III. RESULTADOS

Após a execução dos experimentos, foram obtidos dados referentes às pontuações do agente inteligente em diferentes configurações de sujeira. Cada configuração foi testada em 10 repetições para capturar a variabilidade inerente ao processo

de movimentação pseudo-aleatória do agente e à distribuição aleatória da sujeira no ambiente. Os resultados são apresentados na Tabela II.

Tabela I  
PONTUAÇÕES DO AGENTE INTELIGENTE EM DIFERENTES CONFIGURAÇÕES DE SUJEIRA

Células Sujas	Pontuações									
4	-26	-27	-26	-32	-27	-27	-30	-28	-40	-52
8	-21	-12	-16	-44	-16	-15	-11	-18	-20	-10
12	-11	-5	-54	-3	-1	-3	-9	-27	-11	-8
16	-6	-19	9	7	0	-14	-38	-3	12	9

Tabela II  
ANÁLISE DAS PONTUAÇÕES DO AGENTE INTELIGENTE EM DIFERENTES CONFIGURAÇÕES DE SUJEIRA

Células Sujas	Média	Máximo	Mínimo	Desvio Padrão
4	-31.5	-26	-52	7.93
8	-18.3	-10	-44	9.24
12	-13.2	-1	-54	15.28
16	-4.3	12	-38	14.89

A análise desses resultados revela que o desempenho do agente varia significativamente de acordo com o número de células sujas no ambiente. Em ambientes com um menor número de células sujas (4 e 8), o agente tende a obter pontuações mais negativas, indicando uma dificuldade maior em limpar eficientemente o ambiente. Por outro lado, à medida que o número de células sujas aumenta (12 e 16), observamos uma melhoria na pontuação média do agente, sugerindo uma capacidade relativamente melhor de lidar com ambientes mais sujos.

Além disso, foi gerado um gráfico de box plot (Figura 1) para visualizar e analisar os resultados. O boxplot é um recurso visual que resume os dados para exibir a mediana, quartis e os valores pontuais máximos e mínimos. Portanto, apresenta valores de tendência central, dispersão e simetria dos dados agrupados [2].

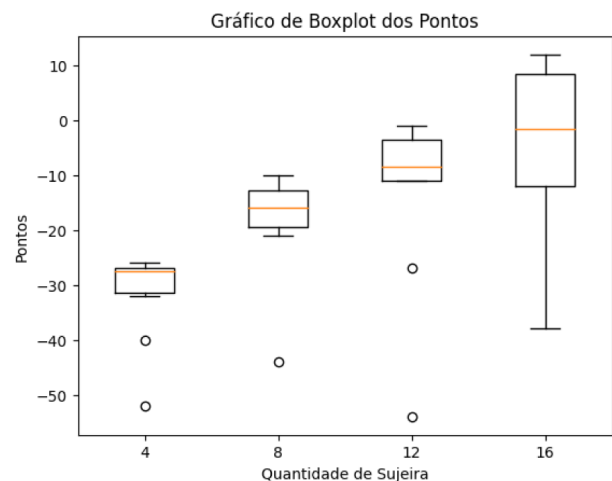


Figura 1. Gráfico de Box Plot das Pontuações do Agente

Ao examinar o gráfico, é evidente que conforme o número de células sujas aumenta, a distribuição das pontuações do agente se torna mais variável. Isso sugere que a performance do agente se torna mais imprevisível em ambientes mais sujos, onde alguns episódios de limpeza podem ser muito eficientes, enquanto outros não.

A análise da amplitude das pontuações confirma essa tendência, mostrando que a diferença entre as pontuações máxima e mínima aumenta à medida que a sujeira aumenta. Essa maior variação indica uma resposta mais diversificada do agente aos diferentes níveis de sujeira, com algumas execuções resultando em pontuações muito altas ou muito baixas em relação à média.

Por fim, a presença de outliers em várias configurações de células sujas ressalta a imprevisibilidade do desempenho do agente em certas circunstâncias. Esses pontos extremos representam casos em que o agente teve um desempenho excepcionalmente bom ou ruim, destacando a complexidade do ambiente e a necessidade de estratégias de limpeza automatizada mais robustas.

#### IV. CONCLUSÃO

Através da implementação de uma abordagem baseada em movimentos pseudo-aleatórios, pode-se avaliar o comportamento do agente em diferentes configurações de sujeira e analisar sua eficácia na tarefa de limpeza.

Os experimentos revelaram que o desempenho do agente varia significativamente de acordo com o número de células sujas no ambiente. Em ambientes com menos sujeira, o agente enfrenta maiores desafios e tende a obter pontuações mais negativas. No entanto, à medida que a quantidade de sujeira aumenta, observamos uma melhoria na pontuação média do agente, indicando uma capacidade relativa melhor de lidar com ambientes mais sujos.

A análise estatística dos resultados, aliada aos gráficos de box plot, permitiu identificar tendências, padrões e anomalias nos dados. O gráfico de box plot, em particular, destacou a variabilidade no desempenho do agente em diferentes cenários de sujeira.

Em resumo, esta pesquisa contribui para o avanço do conhecimento em limpeza automatizada e inteligência artificial, fornecendo informações valiosas para o desenvolvimento de estratégias mais eficientes de limpeza automatizada em ambientes dinâmicos e variáveis. Futuras investigações podem se concentrar em explorar abordagens mais sofisticadas de movimentação do agente, bem como em considerar outros fatores que possam afetar seu desempenho.

#### REFERÊNCIAS

- [1] RUSSEL, S., NORVIG, P. Artificial Intelligence: A Modern Approach. Prentice Hall, 1995.
- [2] NETO, José Valladares e tal. Boxplot: um recurso gráfico para a análise e interpretação de dados quantitativos. Revista Odontológica do Brasil Central, v.26, n. 76, 2017.